



新闻大数据多维分析与智能挖掘

基于 MapReduce、Hive、Spark、HBase 的端到端数据处理流水线



陈双双 2025214403

陈子明 2025214401

张东生 2025214449

2025-12-18

新闻大数据多维分析与智能挖掘

摘要

本文以新闻头条数据集为研究对象，基于 MapReduce、Hive、Spark 和 HBase 四大大数据核心组件，构建了“数据预处理→分析挖掘→特征提取→存储查询”的完整新闻数据处理与分析流水线。实验按流程依次完成核心任务：通过 MapReduce 实现新闻类别统计与 JSON 数据清洗（转换为 Hive 可加载的 TSV 格式）；借助 Hive 构建数据仓库，完成类别分布、核心作者、年度发布量、标题长度等多维统计分析；基于 Spark 三大组件（Core RDD、DataFrame/SQL、MLlib）实现作者影响力计算、热门类别分析与新闻标题 TF-IDF 特征提取；利用 HBase 完成前置实验结果的持久化存储与毫秒级随机查询验证。通过详细阐述各组件的技术实现细节、核心任务逻辑与完整执行步骤，系统验证了大数据技术在新闻领域的可行性与高效性，为新闻数据挖掘、热点趋势追踪、作者影响力评估等应用场景提供了全面的技术支撑与实践参考。

关键词：新闻数据分析、MapReduce、Hive、Spark、HBase

目 录

一、 引言	4
1.1 核心需求分析.....	4
1.2 实验	4
二、 数据集分析	5
2.1 数据集来源.....	5
2.2 数据集内容.....	5
三、 MapReduce 实验.....	6
3.1 实验概述.....	6
3.2 实验目标.....	6
3.2.1 新闻类别统计.....	6
3.2.2 新闻数据清洗.....	7
3.3 实验步骤.....	7
3.3.1 新闻类别统计.....	7
3.3.2 新闻数据清洗.....	13
四、 Hive 实验	19
4.1 实验概述.....	19
4.2 实验目标.....	19
4.2.1 构建新闻数据仓库.....	19
4.2.2 执行新闻分析任务.....	20
4.2.3 保存查询结果到 HDFS	20
4.3 实验步骤.....	20
五、 Spark 实验.....	29
5.1 实验概述.....	29
5.2 实验目标.....	29
5.3 相关概念.....	30
5.3.1 Spark Core RDD	30
5.3.2 Spark DataFrame/SQL.....	30
5.3.3 Spark MLlib	31
5.4 实验步骤.....	31

- 六、HBase 实验 39
 - 6.1 实验概述..... 39
 - 6.2 实验目标..... 39
 - 6.3 实验核心设计..... 40
 - 6.3.1 HBase 表结构设计 40
 - 6.3.2 数据映射规则..... 40
 - 6.4 实验步骤..... 41
- 七、总结 49

一、引言

1.1 核心需求分析

本实验旨在通过大数据技术栈对新闻数据集进行全生命周期处理，核心需求包括——其一是数据预处理需求：新闻原始数据多为非结构化 JSON 格式，需进行清洗转换，过滤无效信息并标准化为结构化数据，为后续分析提供高质量输入；其二是多维度分析需求：需从类别分布、作者影响力、时间趋势、文本特征等维度对新闻数据进行统计分析，挖掘数据潜在价值。其三是高效计算需求：面对大规模新闻数据，需利用分布式计算框架实现高效的并行计算，提升分析效率。其四是结果存储与查询需求：将分析结果持久化存储，并支持快速查询验证，实现数据从计算到应用的闭环。

1.2 实验

由于实验环境不连通，各实验结果需要从 HDFS 下载至本地，最终推送至 GitHub 实现跨环境数据共享。实验流程分为四个核心步骤，各步骤功能与数据流转逻辑如下：

MapReduce 清洗：对原始非结构化 JSON 新闻数据进行预处理，过滤无效信息、提取关键字段并转换为结构化 TSV 格式，为后续分析提供高质量数据基础。

Hive 数据分析：基于清洗后的 TSV 数据构建数据仓库，通过 HiveQL 完成类别统计、作者排名、年度趋势分析等多维度计算。

Spark 深度计算：通过 Spark Core RDD 计算作者影响力、DataFrame 分析热门类别、MLlib 提取标题 TF-IDF 特征，完成高级数据挖掘与特征工程。

HBase 存储查询：获取 Spark 与 Hive 的分析结果，设计适配的 HBase 表结构，通过 Java API 批量写入数据，实现结果的持久化存储；同时通过 HBase Shell 与 Java API 完成毫秒级查询验证，最终将查询日志、表结构文档等推送至 GitHub，完成全流程数据追溯与闭环。

二、数据集分析

2.1 数据集来源

数据集选用 News_Category_Dataset_v3.json，该数据集来自 Kaggle 平台，包含从 HuffPost 获得的 209527 条 2012 年至 2022 年的新闻头条。它可以帮助用户进行文本分类、主题建模等自然语言处理任务。数据集中的每一行记录都包括新闻标题、类别标签以及发布日期等信息。该数据源自新闻媒体公开内容，聚焦新闻的核心元信息与文本内容，经过结构化整理后开放，适用于学术研究和工程实践。

2.2 数据集内容

核心分类字段：category（新闻类别）。最关键的分类维度，常见类别包括政治（POLITICS）、健康（WELLNESS）、娱乐（ENTERTAINMENT）、体育（SPORTS）、科技（TECH）、财经（BUSINESS）等，覆盖主流新闻领域。

数据整体字段结构：包含新闻标题（headline）、正文摘要（short_description）、发布日期（date）、链接（link）、作者（authors）等字段，兼具分类标签与文本内容，支持多维度分析。

统计项	数值
总记录数	209527
总字段数	6
数据维度	209527*6
内存占用(MB)	123.1
总缺失值	0
整体缺失率 (%)	0

表 2-1 数据集内容

三、MapReduce 实验

3.1 实验概述

本实验作为大数据处理技术项目的基础数据预处理与分析阶段，采用 Hadoop MapReduce 框架对大规模新闻数据集进行分布式处理。MapReduce 作为 Hadoop 生态系统的核心计算引擎，通过"分而治之"的并行计算模型，能够高效处理海量非结构化 JSON 数据。本实验设计了两个核心任务：新闻类别统计分析和数据清洗转换，前者展示了 MapReduce 在聚合统计场景下的强大能力，后者为后续 Hive、Spark、HBase 实验提供了标准化的结构化数据输入，体现了大数据流水线中数据预处理的关键作用。




图 3-1 Mapreduce 实验流程图

3.2 实验目标

3.2.1 新闻类别统计

目的：对新闻数据进行分类统计，输出每类新闻出现次数。

技术难点：

1. 处理大规模 JSON 数据的分布式解析，需要高效的 JSON 解析库（Jackson）
2. 在 Map 阶段实现容错机制，过滤格式异常的 JSON 记录
3. 利用 MapReduce 的 Shuffle 机制自动将相同类别的数据聚合到同一 Reducer
4. 处理数据倾斜问题（某些类别可能包含大量记录，需要合理的分区策略）

此任务用于展示 MapReduce 在分布式聚合统计场景下的核心能力，通过 Map 阶段的并行解析和 Reduce 阶段的汇总计算，实现对海量数据的快速分类统计。

3.2.2 新闻数据清洗

目的：将原始 JSON Lines 数据清洗为 Hive 可加载的结构化 TSV 文件。

技术难点：

- 1. 实现多字段提取与格式转换，从嵌套 JSON 结构转换为扁平化 TSV 格式
- 2. 设计数据质量校验规则，过滤关键字段缺失的脏数据
- 3. 处理特殊字符和编码问题，确保 TSV 格式的字段分隔符（tab）不会与数据内容冲突
- 4. 优化 MapReduce 作业配置，减少网络传输开销（使用 NullWritable 作为 Key 避免不必要的 Shuffle）

清洗内容包括：

- 1. 过滤无效 JSON（通过异常捕获机制实现容错）
- 2. 过滤关键信息为空（如 category、date、headline）的记录（数据质量保证）
- 3. 提取字段：category、date、authors、headline、short_description（字段映射与转换）
- 4. 输出 TSV 格式（字段以 tab 分隔，便于 Hive 直接加载）

该任务的输出将作为 Hive 实验的输入，体现了大数据流水线中 ETL(Extract-Transform-Load) 流程的 Extract 和 Transform 阶段。

3.3 实验步骤

3.3.1 新闻类别统计

- 1. GitHub 仓库结构准备

```
news-bigdata-project/
├── mapreduce/
│   ├── src/
│   │   ├── CategoryCountMapper.java
│   │   ├── CategoryCountReducer.java
│   │   └── CategoryCountDriver.java
│   ├── News_Category_Dataset_v3.json
│   ├── build.sh
│   └── README.md (非必须)
```

图 3-2 Github 仓库结构准备

- 2. 克隆 GitHub 仓库


```
dolphin@fa68015a5490:~$ git clone git@github.com:Freya277/news-bigdata-project.git
Cloning into 'news-bigdata-project'...
remote: Enumerating objects: 52, done.
remote: Total 52 (delta 0), reused 0 (delta 0), pack-reused 52 (from 1)
Receiving objects: 100% (52/52), 157.45 MiB | 4.35 MiB/s, done.
Resolving deltas: 100% (8/8), done.
Checking connectivity... done.
dolphin@fa68015a5490:~$ cd news-bigdata-project/mapreduce
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ ls
build.sh  News_Category_Dataset_v3.json  src
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$
```

图 3-3 克隆 Github 仓库

3. 启动 Hadoop

```
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ cd /apps/hadoop/sbin
dolphin@fa68015a5490:/apps/hadoop/sbin$ ./start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as dolphin in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [fa68015a5490]
fa68015a5490: Warning: Permanently added 'fa68015a5490,10.42.199.197' (ECDSA) to
the list of known hosts.
Starting resourcemanager
Starting nodemanagers
dolphin@fa68015a5490:/apps/hadoop/sbin$ jps
1936 Jps
1445 NodeManager
471 NameNode
1291 ResourceManager
876 SecondaryNameNode
623 DataNode
dolphin@fa68015a5490:/apps/hadoop/sbin$
```

图 3-4 启动 Hadoop

4. 将 JSON 数据上传到 HDFS

```
dolphin@fa68015a5490:/apps/hadoop/sbin$ cd ~/news-bigdata-project/mapreduce
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ hdfs dfs -mkdir /news_project
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ hdfs dfs -put News_Category_Dataset_v3.json /news_project/
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ hdfs dfs -ls /news_project
Found 1 items
-rw-r--r-- 1 dolphin supergroup 87295572 2025-11-25 13:06 /news_project/News_Category_Dataset_v3.json
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$
```

图 3-5 将 JSON 数据上传到 HDFS

5. 编写 MapReduce 程序

在 GitHub 中放入以下文件：

- src/CategoryCountMapper.java
- src/CategoryCountReducer.java
- src/CategoryCountDriver.java

这些代码用于：

- 解析 JSON 行
- 取出“category”字段
- 实现类别计数

(1) CategoryCountReducer.java

```
package mapreduce;

import java.io.IOException;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.LongWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Mapper;
import com.fasterxml.jackson.databind.JsonNode;
import com.fasterxml.jackson.databind.ObjectMapper;

public class CategoryCountMapper extends Mapper<LongWritable, Text, Text, IntWritable> {
    private final static IntWritable one = new IntWritable(1);
    private Text category = new Text();
    private ObjectMapper jsonMapper = new ObjectMapper();

    @Override
    protected void map(LongWritable key, Text value, Context context) throws IOException, InterruptedException {
        try {
            JsonNode node = jsonMapper.readTree(value.toString());
            String cat = node.get("category").asText();
            category.set(cat);
            context.write(category, one);
        } catch (Exception e) {
            // Ignore malformed JSON
        }
    }
}
```

图 3-6 CategoryCountMapper.java

这是 MapReduce 作业的 Map 阶段处理类，负责将输入的 JSON 格式新闻数据转换为键值对形式，为后续的聚合统计做准备。

核心设计要点：

- 继承 Mapper 泛型类：Mapper<LongWritable, Text, Text, IntWritable> 定义输入输出类型
- 使用 Jackson 库进行 JSON 解析：ObjectMapper 是高性能的 JSON 解析工具，能够高效处理大规模数据流
- 容错机制：通过 try-catch 捕获 JSON 解析异常，自动跳过格式错误的记录，确保作业不会因个别脏数据而失败
- 对象复用优化：将 IntWritable one 和 Text category 声明为类成员变量，避免在 map 方法中频繁创建对象，减少 GC 压力

- 输出键值对设计：输出 (category, 1) 键值对，其中 value 固定为 1，表示该类别出现一次；后续在 Shuffle 阶段，相同 category 的记录会被自动聚合到同一个 Reducer 执行流程：每个 MapTask 并行处理 HDFS 上的数据分片，对每条 JSON 记录提取 category 字段并输出 (category, 1)，实现了分布式并行解析。

(2) CategoryCountReducer.java

```
public class CategoryCountReducer extends Reducer<Text, IntWritable, Text, IntWritable> {

    @Override
    protected void reduce(Text key, Iterable<IntWritable> values, Context context)
        throws IOException, InterruptedException {

        int sum = 0;
        for (IntWritable val : values) {
            sum += val.get();
        }
        context.write(key, new IntWritable(sum));
    }
}
```

图 3-7 CategoryCountReducer.java

这是 MapReduce 作业的 Reduce 阶段处理类，负责对 Map 阶段输出的键值对进行聚合计算，实现最终的类别统计。

核心设计要点：

- 继承 Reducer 泛型类：Reducer<Text, IntWritable, Text, IntWritable> 定义了输入输出类型
- Shuffle 机制的作用：在 Map 和 Reduce 之间，Hadoop 框架会自动执行 Shuffle 操作，将相同 key (category) 的所有 value (1) 聚合到同一个 Reducer，这是 MapReduce 实现分布式聚合的核心机制
- 迭代器模式：Iterable<IntWritable> values 是一个迭代器，不能直接获取大小，必须通过遍历累加；这种设计避免了将大量数据加载到内存，支持处理任意大小的数据集
- 累加逻辑：遍历所有 value，将每个 IntWritable 的值累加到 sum 中，最终得到该类别的总出现次数
- 输出结果：输出 (category, totalCount) 键值对，完成该类别的统计

执行流程：每个 Reducer 处理一个或多个类别（取决于分区策略），对每个类别累加其所有计数，输出最终的统计结果。多个 Reducer 并行工作，实现高效的分布式聚合计算。

(3) CategoryCountDriver.java

```

public class CategoryCountDriver {
    public static void main(String[] args) throws Exception {
        Configuration conf = new Configuration();
        Job job = Job.getInstance(conf, "News Category Count");

        job.setJarByClass(CategoryCountDriver.class);
        job.setMapperClass(CategoryCountMapper.class);
        job.setReducerClass(CategoryCountReducer.class);

        job.setOutputKeyClass(Text.class);
        job.setOutputValueClass(IntWritable.class);

        TextInputFormat.addInputPath(job, new Path(args[0]));
        TextOutputFormat.setOutputPath(job, new Path(args[1]));

        System.exit(job.waitForCompletion(true) ? 0 : 1);
    }
}

```

图 3-8 CategoryCountDriver.java

这是 MapReduce 作业的驱动类 (Driver)，负责配置作业参数、提交作业到 Hadoop 集群并监控执行状态。

核心设计要点：

- Configuration 对象：封装了 Hadoop 集群的配置信息（如 HDFS 地址、资源管理器地址等），作业会根据这些配置连接到集群
- Job 对象：代表一个完整的 MapReduce 作业，通过 Job.getInstance() 创建，第二个参数是作业名称，用于在集群管理界面中标识该作业
- setJarByClass()：指定包含 Mapper 和 Reducer 类的 JAR 包，Hadoop 会将此 JAR 分发到各个节点执行
- Mapper/Reducer 类绑定：通过 setMapperClass() 和 setReducerClass() 指定具体的处理类
- 输出类型声明：setOutputKeyClass() 和 setOutputValueClass() 声明最终输出的键值对类型，Hadoop 会据此进行序列化
- 输入输出路径：通过 TextInputFormat.addInputPath() 指定输入路径（支持目录，会自动处理目录下所有文件），通过 TextOutputFormat.setOutputPath() 指定输出路径（必须不存在，避免覆盖）
- 作业提交与监控：job.waitForCompletion(true) 提交作业并等待完成，参数 true 表示打印进度信息；返回 true 表示成功，false 表示失败

执行流程：Driver 类在客户端运行，将作业配置和代码打包提交 Hadoop 集群；ResourceManager 分配资源，NodeManager 启动 MapTask 和 ReduceTask；作业完成后返回执行结果。

6. 编译 MapReduce 程序

编译说明：MapReduce 程序需要编译为 JAR 包才能在 Hadoop 集群上运行。编译过程需要包含 Hadoop 的核心库和第三方依赖（如 JacksonJSON 库）。

build.sh 内容：

```
mkdir -p build

javac -cp $(hadoop classpath):./lib/* -d build src/*.java

jar -cvf categorycount.jar -C build .
```

图 3-9 build.sh 代码

编译结果：生成 categorycount.jar，包含所有编译后的类文件和必要的包结构，可直接通过 hadoop jar 命令提交到集群执行。

7. 运行 MapReduce 程序

```
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ hadoop jar categorycount.jar mapreduce.CategoryCountDriver /news_project /news_output

2025-11-25 13:16:04,193 INFO mapreduce.Job: map 0% reduce 0%
2025-11-25 13:16:27,571 INFO mapreduce.Job: map 21% reduce 0%
2025-11-25 13:16:33,647 INFO mapreduce.Job: map 100% reduce 0%
2025-11-25 13:16:42,809 INFO mapreduce.Job: map 100% reduce 100%
2025-11-25 13:16:43,839 INFO mapreduce.Job: Job job_1764075931929_0001 completed successfully
```

图 3-10、3-11 运行 MapReduce 程序

8. 查看 HDFS 结果

```
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ hdfs dfs -cat /news_output/part-r-00000
ARTS 1509
ARTS & CULTURE 1339
BLACK VOICES 4583
BUSINESS 5992
COLLEGE 1144
COMEDY 5400
CRIME 3562
CULTURE & ARTS 1074
DIVORCE 3426
EDUCATION 1014
ENTERTAINMENT 17362
ENVIRONMENT 1444
FIFTY 1401
FOOD & DRINK 6340
GOOD NEWS 1398
GREEN 2622
HEALTHY LIVING 6694
HOME & LIVING 4320
IMPACT 3484
```

图 3-12 查看 HDFS 结果

9. 将结果从 HDFS 下载到本地

```
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ hdfs dfs -get /news_output ./mr_result

dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$ ls mr_result
part-r-00000 _SUCCESS
dolphin@fa68015a5490:~/news-bigdata-project/mapreduce$
```

图 3-13 将结果从 HDFS 下载到本地

10. 将最终文件推送回 GitHub

```
Counting objects: 12, done.
Delta compression using up to 36 threads.
Compressing objects: 100% (9/9), done.
Writing objects: 100% (12/12), 6.02 KiB | 0 bytes/s, done.
Total 12 (delta 0), reused 0 (delta 0)
remote: To git@github.com:Freya277/news-bigdata-project.git
       f65293f..7e25933  main -> main
dolphin@fa68015a5490:~/news-bigdata-project$
```

图 3-14 将最终文件推送回 Github

3.3.2 新闻数据清洗

1. GitHub 仓库结构准备

```
news-bigdata-project/
├── mapreduce_clean/
│   ├── src/
│   │   ├── CleanMapper.java
│   │   ├── CleanReducer.java
│   │   └── CleanDriver.java
│   ├── News_Category_Dataset_v3.json
│   ├── build.sh
│   └── README.md (非必须)
```

图 3-15 Github 仓库结构准备

2. 克隆 GitHub 仓库

```
From github.com:Freya277/news-bigdata-project
 7e25933..3626d56  main      -> origin/main
Updating 7e25933..3626d56
Fast-forward
 mapreduce_clean/News_Category_Dataset_v3.json | 209527 ++++++
 mapreduce_clean/build.sh                      |      6 +
 mapreduce_clean/src/CleanDriver.java          |     33 +
 mapreduce_clean/src/CleanMapper.java          |     40 +
 mapreduce_clean/src/CleanReducer.java         |     16 +
 5 files changed, 209622 insertions(+)
 create mode 100644 mapreduce_clean/News_Category_Dataset_v3.json
 create mode 100644 mapreduce_clean/build.sh
 create mode 100644 mapreduce_clean/src/CleanDriver.java
 create mode 100644 mapreduce_clean/src/CleanMapper.java
 create mode 100644 mapreduce_clean/src/CleanReducer.java
dolphin@75eb41a113a5:~/news-bigdata-project$
```

图 3-16 克隆 Github 仓库

3. 启动 Hadoop


```
dolphin@75eb41a113a5:~/news-bigdata-project$ cd /apps/hadoop/sbin
dolphin@75eb41a113a5:/apps/hadoop/sbin$ jps
254 Jps
dolphin@75eb41a113a5:/apps/hadoop/sbin$ ./start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as dolphin in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [75eb41a113a5]
75eb41a113a5: Warning: Permanently added '75eb41a113a5,10.42.186.150' (ECDSA) to
the list of known hosts.
Starting resourcemanager
Starting nodemanagers
dolphin@75eb41a113a5:/apps/hadoop/sbin$ jps
914 SecondaryNameNode
1314 ResourceManager
644 DataNode
506 NameNode
1994 Jps
1469 NodeManager
dolphin@75eb41a113a5:/apps/hadoop/sbin$
```

图 3-17 启动 Hadoop

4. 将 JSON 数据上传到 HDFS

```
dolphin@75eb41a113a5:/apps/hadoop/sbin$ cd ~/news-bigdata-project/mapreduce_clean
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$ hdfs dfs -mkdir /news_raw
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$ hdfs dfs -put News_Category_Dataset_v3.json /news_raw/
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$ hdfs dfs -ls /news_raw
Found 1 items
-rw-r--r-- 1 dolphin supergroup 87295572 2025-11-25 13:58 /news_raw/News_Category_Dataset_v3.json
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$
```

图 3-18 将 JSON 数据上传到 HDFS

5. 编写 MapReduce 程序

(1) CleanMapper.java

```

public class CleanMapper extends Mapper<LongWritable, Text, NullWritable, Text> {

    private ObjectMapper json = new ObjectMapper();
    private Text cleaned = new Text();

    @Override
    protected void map(LongWritable key, Text value, Context context)
        throws IOException, InterruptedException {
        try {
            JsonNode node = json.readTree(value.toString());

            String category = node.get("category").asText();
            String date = node.get("date").asText();
            String authors = node.get("authors").asText();
            String headline = node.get("headline").asText();
            String shortDesc = node.get("short_description").asText();

            if (category.isEmpty() || date.isEmpty() || headline.isEmpty()) return;

            String out = category + "\t" + date + "\t" +
                authors + "\t" + headline + "\t" + shortDesc;

            cleaned.set(out);
            context.write(NullWritable.get(), cleaned);

        } catch (Exception e) {
            // skip invalid JSON
        }
    }
}

```

图 3-19 CleanMapper. java

这是数据清洗作业的 Map 阶段处理类，负责将 JSON 格式的原始数据转换为结构化的 TSV 格式，并实现数据质量校验。

核心设计要点：

- 输出 Key 使用 NullWritable: Mapper<LongWritable, Text, NullWritable, Text>中输出 Key 为 NullWritable，这是一个特殊的 Hadoop 类型，表示“空键”。
- 多字段提取：从 JSON 对象中提取 5 个关键字段(category、date、authors、headline、short_description)，实现从嵌套结构到扁平结构的转换
- 数据质量校验：if(category.isEmpty() || date.isEmpty() || headline.isEmpty())检查关键字段是否为空，过滤掉不符合质量要求的记录，确保输出数据的完整性
- TSV 格式构建：使用制表符(\t)作字段分隔符，构建标准 TSV 格式，便于后续 Hive 直接加载
- 容错机制：通过 try-catch 捕获 JSON 解析异常，自动跳过格式错误的记录，保证作业健壮性

执行流程：每个 MapTask 并行处理数据分片，对每条 JSON 记录进行解析、校验和格式转换，输出清洗后的 TSV 格式数据。由于使用 NullWritable 作为 Key，所有有效记录都会被发送到同一个 Reducer（或根据分区策略分配到多个 Reducer）。

(2) CleanReducer. java


```

package mapreduce_clean;

import java.io.IOException;
import org.apache.hadoop.io.NullWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Reducer;

public class CleanReducer extends Reducer<NullWritable, Text, NullWritable, Text> {
    @Override
    protected void reduce(NullWritable key, Iterable<Text> values, Context context)
        throws IOException, InterruptedException {
        for (Text t : values) {
            context.write(NullWritable.get(), t);
        }
    }
}

```

图 3-20 CleanReducer.java

这是数据清洗作业的 Reduce 阶段处理类，由于清洗的核心逻辑（解析、校验、格式转换）已在 Map 阶段完成，Reducer 仅负责将清洗后的数据直接输出。

核心设计要点：

- Pass-through 模式：Reducer 不执行任何聚合或转换操作，只是将 Map 阶段输出的数据原样传递，这种模式称为“直通式”处理
- 迭代器遍历：Iterable<Text>values 包含所有发送到该 Reducer 的清洗后记录，通过简单的 for 循环遍历并输出
- 输出格式保持一致：输出 Key 仍为 NullWritable，Value 为清洗后的 TSV 格式文本，与 Map 阶段输出格式一致

执行流程：每个 Reducer 接收来自多个 MapTask 的清洗后数据，由于所有记录的 Key 都是 NullWritable，它们会被聚合到同一个 Reducer（或根据分区策略分配到多个 Reducer）。Reducer 遍历所有记录并直接输出，最终生成结构化的 TSV 文件，供后续 Hive 实验使用。

(3) CleanDriver.java

```

public class CleanDriver {
    public static void main(String[] args) throws Exception {
        if (args.length != 2) {
            System.err.println("Usage: CleanDriver <input> <output>");
            System.exit(-1);
        }

        Configuration conf = new Configuration();
        Job job = Job.getInstance(conf, "News_Clean");

        job.setJarByClass(CleanDriver.class);
        job.setMapperClass(CleanMapper.class);
        job.setReducerClass(CleanReducer.class);

        job.setOutputKeyClass(org.apache.hadoop.io.NullWritable.class);
        job.setOutputValueClass(org.apache.hadoop.io.Text.class);

        FileInputFormat.addInputPath(job, new Path(args[0]));
        FileOutputFormat.setOutputPath(job, new Path(args[1]));
    }
}

```

图 3-21 CleanDriver.java

这是数据清洗作业的驱动类，负责配置作业参数、参数校验和作业提交。

核心设计要点：

- 参数校验：通过 `if(args.length!=2)` 检查命令行参数数量，确保输入路径和输出路径都已提供，提高程序的健壮性和用户体验
- 输入输出格式类：使用 `FileInputFormat` 和 `FileOutputFormat`（而非任务 1 的 `TextInputFormat` 和 `TextOutputFormat`），两者功能类似，都是处理文本文件的输入输出格式
- 输出类型配置：
`setOutputKeyClass(NullWritable.class)/setOutputValueClass(Text.class)` 明确声明输出类型，与 Mapper/Reducer 的输出类型保持一致

执行流程：Driver 在客户端运行，验证参数后创建 Job 对象并配置各项参数，提交作业到 Hadoop 集群；集群执行 Map 和 Reduce 任务，完成数据清洗并输出 TSV 格式文件。

6. 编译 MapReduce 程序

编译脚本生成 `clean.jar`，用于提交清洗作业。

`build.sh` 内容：

```
mkdir -p build
javac -cp $(hadoop classpath):./lib/* -d build src/*.java
jar -cvf clean.jar -C build .
```

图 3-22 build.sh

7. 运行 MapReduce 程序

```
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$ hadoop jar clean.jar mapreduce_clean.CleanDriver /news_raw /news_cleaned
2025-11-25 14:02:47,601 INFO mapreduce.Job: map 0% reduce 0%
2025-11-25 14:03:09,656 INFO mapreduce.Job: map 100% reduce 0%
2025-11-25 14:03:19,913 INFO mapreduce.Job: map 100% reduce 100%
2025-11-25 14:03:21,947 INFO mapreduce.Job: Job job_1764079000904_0001 completed successfully
```

图 3-23、3-24 运行 MapReduce 程序

8. 查看 HDFS 结果

```

POLITICS      2015-12-05      William Bradley, ContributorPolitical Analyst  A
n Odd Home-Grown Jihadism Hits Hard in California: What To Do  The purpose of t
errorism, after all, is to induce terror. And it certainly never made any sense
that a dispute at a holiday party would lead to an attack from a black-clad pair
geared up for Iwo Jima. So this is exactly what it looked like from early on, a
case of home-grown jihadism.
GREEN      2015-12-05      David Yarnold, ContributorPresident, National Audubon So
ciety  What #BirdsTellUs About Climate Change -- And How We Can Make a Differen
ce  Today, birds are giving us clear warnings about the health of our world.
And they're showing us what we need to do to make a difference.
EDUCATION      2015-12-05      C. M. Rubin, ContributorBlogger and author, 'The
Real Alice in Wonderland'  The Global Search for Education: With the World
in Mind
TRAVEL      2015-12-05      Conde Nast Traveler, ContributorCondeNastTraveler.com T
he 5 Most Beautiful Places In The World Pinpointing every breathtaking place on
the planet could take a lifetime, but we think that these 5 otherworldly landsca
pes and awe-inspiring natural wonders need to move to the very top of your trave
l bucket list.

```

图 3-25 查看 HDFS 结果

9. 将结果从 HDFS 下载到本地

```

dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$ mkdir cleaned_resul
t
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$ hdfs dfs -get /news
_cleaned cleaned_result/
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$

```

图 3-26 将结果从 HDFS 下载到本地

10. 将最终文件推送回 GitHub

```

Counting objects: 12, done.
Delta compression using up to 36 threads.
Compressing objects: 100% (10/10), done.
Writing objects: 100% (12/12), 18.75 MiB | 2.07 MiB/s, done.
Total 12 (delta 0), reused 0 (delta 0)
remote: To git@github.com:Freya277/news-bigdata-project.git
3626d56..7c26c1b  main -> main
dolphin@75eb41a113a5:~/news-bigdata-project/mapreduce_clean$

```

图 3-27 将最终文件推送回 Github

四、Hive 实验

4.1 实验概述

本实验作为大数据处理技术项目的数据仓库构建与分析阶段，采用 Apache Hive 作为数据仓库工具，对 MapReduce 清洗后的结构化数据进行存储和深度分析。Hive 基于 Hadoop 构建，提供了类似 SQL 的查询语言（HiveQL），使得熟悉 SQL 的数据分析师能够直接对存储在 HDFS 上的大数据进行查询分析，无需编写复杂的 MapReduce 程序。本实验的核心价值在于：将 MapReduce 的批处理能力与 SQL 的易用性相结合，实现了从原始数据到业务洞察的快速转换，为后续 Spark 高级分析和 HBase 实时查询提供了高质量的数据基础。




图 4-1 Hive 流程图

4.2 实验目标

4.2.1 构建新闻数据仓库

1. 创建 newsdb 数据库：建立独立的数据仓库命名空间，便于数据管理和权限控制
2. 创建外部表 news_cleaned：使用外部表（ExternalTable）而非内部表（ManagedTable），数据仍存储在 HDFS 上，Hive 只管理元数据；优势是删除表时不会删除 HDFS 数据，保证数据安全
3. 加载/news_cleaned 数据：通过 LOCATION 子句直接指向 HDFS 路径，Hive 自动读取数据，无需显式导入，实现零拷贝数据加载

4.2.2 执行新闻分析任务

依据数据集特点设计 Hive 查询任务，展示 HiveQL 在多维统计分析场景下的强大能力：

1. **查询每个类别的新闻数量：**使用 GROUPBY 和 COUNT(*) 实现分组聚合，展示 Hive 在分类统计中的应用
2. **查询新闻最多的前 10 个作者：**结合 GROUPBY、ORDERBY 和 LIMIT，实现 Top-N 查询，体现 Hive 在排名分析中的优势
3. **按年份统计新闻数量：**使用字符串函数 substr() 提取日期字段中的年份，展示 Hive 在时间维度分析中的灵活性
4. **查询标题长度平均值：**使用 AVG() 和 length() 函数计算文本特征，为后续 SparkMLlib 文本挖掘提供基础统计信息

技术难点：

1. 字符串处理：日期字段提取需要精确的字符串操作，避免格式不一致导致的数据错误
2. 空值处理：作者字段可能为空，需要 WHERE authors IS NOT NULL AND authors != '' 过滤，确保统计准确性
3. 性能优化：大规模数据的聚合查询可能涉及全表扫描，需要合理设计查询逻辑以减少计算开销

4.2.3 保存查询结果到 HDFS

将分析结果持久化到 HDFS，为后续 Spark 和 HBase 实验提供输入数据：

- /hive_output/category_count：类别统计结果，用于 Spark 热门类别分析
- /hive_output/top_authors：作者排名结果，用于 Spark 作者影响力计算
- /hive_output/yearly_count：年度统计结果，用于 HBase 时间维度查询
- /hive_output/headline_avglen：标题平均长度，用于文本特征分析

4.3 实验步骤

1. GitHub 仓库结构准备

```
dolphin@dac5dd1ccb36:~$ git clone git@github.com:Freya277/news-bigdata-project.git
Cloning into 'news-bigdata-project'...
The authenticity of host 'github.com (20.205.243.166)' can't be established.
ECDSA key fingerprint is SHA256:p2QAMXNIC1TJYWeIOttrVc98/R1BUFWu3/LiyKgUfQM.
Are you sure you want to continue connecting (yes/no)? yes
Warning: Permanently added 'github.com,20.205.243.166' (ECDSA) to the list of known hosts.
remote: Enumerating objects: 84, done.
remote: Total 84 (delta 0), reused 0 (delta 0), pack-reused 84 (from 2)
Receiving objects: 100% (84/84), 176.21 MiB | 3.81 MiB/s, done.
Resolving deltas: 100% (12/12), done.
Checking connectivity... done.
dolphin@dac5dd1ccb36:~$
```

图 4-2 Github 仓库结构准备

2. 启动 Hadoop

```
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$ jps
1537 ResourceManager
1010 DataNode
2100 Jps
1702 NodeManager
856 NameNode
1278 SecondaryNameNode
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$
```

图 4-3 启动 Hadoop

3. 将文件上传到 HDFS

```
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$ hdfs dfs -mkdir /news_cleaned
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$ hdfs dfs -put ~/news-bigdata-project/map
reduce_clean/cleaned_result/news_cleaned/part-r-00000 /news_cleaned/
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$ hdfs dfs -ls /news_cleaned/
Found 1 items
-rw-r--r-- 1 dolphin supergroup 47885079 2025-11-25 14:39 /news_cleaned/part
-r-00000
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$
```

图 4-4 将文件上传到 HDFS

4. 启动 MySQL

```
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$ sudo /etc/init.d/mysql start
* Starting MySQL database server mysqld
No directory, logging in with HOME=/
[ OK ]
dolphin@dac5dd1ccb36:/apps/hadoop/sbin$
```

图 4-5 启动 MySQL

5. 启动 Hive

```
d 5.7.6+ requirements SSL connection must be established by default if explicit
option isn't set. For compliance with existing applications not using SSL the ve
rifyServerCertificate property is set to 'false'. You need either to explicitly
disable SSL by setting useSSL=false, or set useSSL=true and provide truststore f
or server certificate verification.
hive>
```

图 4-6 启动 Hive

6. 创建 Hive 数据库

```
hive> CREATE DATABASE IF NOT EXISTS newsdb;
OK
Time taken: 0.811 seconds
hive> USE newsdb;
OK
Time taken: 0.021 seconds
hive> SHOW TABLES;
OK
Time taken: 0.228 seconds
hive> █
```

图 4-7 创建 Hive 数据库

7. 创建新闻外部表

外部表创建说明：

```
CREATE EXTERNAL TABLE news_cleaned (
  category string,
  date string,
  authors string,
  headline string,
  short_description string
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
STORED AS TEXTFILE
LOCATION '/news_cleaned';
```

图 4-8 创建外部表

外部表优势：

- 数据安全：删除表时不会删除 HDFS 数据，避免误操作导致数据丢失
- 数据共享：多个 Hive 表或 Spark 作业可以共享同一份 HDFS 数据，无需复制
- 灵活管理：可以在 Hive 外部直接操作 HDFS 数据，Hive 会自动感知数据变化

```
hive> CREATE EXTERNAL TABLE news_cleaned (
  > category STRING,
  > `date` STRING,
  > authors STRING,
  > headline STRING,
  > short_description STRING
  > )
  > ROW FORMAT DELIMITED
  > FIELDS TERMINATED BY '\t'
  > STORED AS TEXTFILE
  > LOCATION '/news_cleaned';
OK
Time taken: 0.342 seconds
hive> █
```

图 4-9 外部表

8. 验证数据是否正确加载


```
hive> SELECT * FROM news_cleaned LIMIT 3;
OK
SPORTS 2012-01-28 Dwight Howard Rips Teammates After Magic Loss To
Hornets The five-time all-star center tore into his teammates Friday nig
ht after Orlando committed 23 turnovers en route to losing
SPORTS 2012-01-28 Aldon Smith Arrested: 49ers Linebacker Busted Fo
r DUI CORRECTION: An earlier version of this story incorrectly stated the loca
tion of KTVU and the 2011 league leader in sacks
SPORTS 2012-01-28 Giants Over Patriots, Jets Over Colts Among Mos
t Improbable Super Bowl Upsets Of All Time (VIDEOS) Leading up to Super Bowl
XLVI, the most talked about game could end up being one that occurred a few yea
rs ago. After all
Time taken: 0.093 seconds, Fetched: 3 row(s)
hive>
```

图 4-10 验证数据是否正确加载

9. Hive 数据分析任务

任务 1：按类别统计新闻数量

查询设计说明：这是一个典型的分组聚合查询，展示了 Hive 在分类统计场景下的核心能力。

查询逻辑：

```
SELECT category, COUNT(*) AS cnt
FROM news_cleaned
GROUP BY category
ORDER BY cnt DESC;
```

图 4-11 查询逻辑 1

技术要点：

- GROUP BY category：按类别分组，将相同类别的记录聚合在一起
- COUNT(*)：统计每个分组中的记录数量，*表示统计所有行（包括 NULL 值）
- ORDER BY cnt DESC：按计数降序排序，便于查看最热门的新闻类别

执行计划：Hive 会将此查询转换为 MapReduce 作业，Map 阶段按 category 分组，Reduce 阶段进行计数和排序

保存到 HDFS：

```
INSERT OVERWRITE DIRECTORY '/hive_output/category_count'
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
SELECT category, COUNT(*)
FROM news_cleaned
GROUP BY category;
```

图 4-12 保存到 HDFS1

查询结果分析：

POLITICS	35602
QUEER VOICES	6347
RELIGION	2577
SCIENCE	2206
SPORTS	5077
STYLE	2254
STYLE & BEAUTY	9814
TASTE	2096
TECH	2104
THE WORLDPOST	3664
TRAVEL	9900
U.S. NEWS	1377
WEDDINGS	3653
WEIRD NEWS	2777
WELLNESS	17945
WOMEN	3572
WORLD NEWS	3299
WORLDPOST	2579

图 4-13 类别统计结果

根据输出文件，可以观察到不同类别的新闻数量分布，例如 POLITICS（政治）类别包含最多的新闻，这反映了新闻数据集的类别分布特征。

任务 2：新闻最多的前 10 位作者

查询设计说明：这是一个 Top-N 查询，结合了数据过滤、分组聚合、排序和限制结果集，展示了 Hive 在排名分析场景下的综合能力。

查询逻辑：

```
SELECT authors, COUNT(*) AS cnt
FROM news_cleaned
WHERE authors IS NOT NULL AND authors != ''
GROUP BY authors
ORDER BY cnt DESC
LIMIT 10;
```

图 4-14 查询逻辑 2

技术要点：

- WHERE 子句过滤: authors IS NOT NULL AND authors != '' 过滤掉空值和空字符串, 确保只统计有效的作者数据
- GROUP BY authors: 按作者分组, 统计每个作者的文章数量
- ORDER BY cnt DESC: 按文章数量降序排序, 找出最活跃的作者
- LIMIT 10: 限制结果集为前 10 条, 实现 Top-10 查询

保存到 HDFS:

```
INSERT OVERWRITE DIRECTORY '/hive_output/top_authors'
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
SELECT
    authors,
    COUNT(*) AS article_count
FROM
    news_cleaned
WHERE
    authors IS NOT NULL AND authors != ''
GROUP BY
    authors
ORDER BY
    article_count DESC
LIMIT 10;
```

图 4-15 保存到 HDFS 2

查询结果分析:

Lee Moran	2954
Ron Dicker	2219
Ed Mazza	1590
Mary Papenfuss	1566
Reuters, Reuters	1563
Cole Delbyck	1266
Carly Ledbetter	1170
Curtis M. Wong	1146
Andy McDonald	1100
David Moye	1067

图 4-16 前十作者统计结果

输出结果展示了新闻数据集中最活跃的 10 位作者及其文章数量, 这些作者可能是平台的核心内容贡献者, 其影响力值得进一步分析。

任务 3: 按年份统计新闻数量

查询设计说明: 这是一个时间维度分析查询, 通过字符串函数提取日期字段中的年份, 实现按年份的聚合统计, 展示了 Hive 在时间序列分析中的应用。

日期字段处理：由于 date 字段格式如“2022-09-23”（YYYY-MM-DD），可以用 substr() 函数提取前 4 个字符作为年份。

```
SELECT substr(`date`,1,4) AS year, COUNT(*) AS cnt
FROM news_cleaned
GROUP BY substr(`date`,1,4)
ORDER BY year;
```

图 4-17 查询逻辑 3

技术要点：

- 字符串函数 substr()：substr(date, 1, 4) 从日期字符串的第 1 个字符开始，提取 4 个字符（即年份部分）
- 反引号转义：date 是 Hive 的保留关键字，使用反引号`date`可以避免语法冲突
- GROUP BY 表达式：GROUP BY substr(date, 1, 4) 使用与 SELECT 中相同的表达式，确保分组逻辑一致
- ORDER BY year：按年份升序排序，便于观察新闻数量随时间的变化趋势

保存到 HDFS：

```
INSERT OVERWRITE DIRECTORY '/hive_output/yearly_count'
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
SELECT
    substr(`date`, 1, 4) AS year,
    COUNT(*)
FROM
    news_cleaned
GROUP BY
    substr(`date`, 1, 4)
ORDER BY
    year;
```

图 4-18 保存到 HDFS 3

查询结果分析：

2012	31362
2013	34604
2014	32347
2015	32001
2016	32098
2017	29889
2018	9734
2019	2005
2020	2054
2021	2066
2022	1398

图 4-19 时间跨度分析

输出结果可以揭示新闻数据集的时间跨度（如 2012-2022），以及不同年份的新闻发布量变化，可能反映出新闻平台的发展历程或特定年份的重大事件影响。

任务 4：标题平均长度（文本特征分析）

查询设计说明：这是一个文本特征提取查询，通过计算标题的平均长度，为后续 Spark MLlib 文本挖掘任务提供基础统计特征，展示了 Hive 在文本分析预处理中的应用。

文本长度计算：Hive 中使用 `length()` 函数计算字符串长度（字符数）。

```
SELECT AVG(length(headline)) AS avg_headline_len
FROM news_cleaned;
```

图 4-20 查询逻辑 4

技术要点：

- `length()` 函数：计算字符串的字符数（不是字节数），对于英文文本，字符数等于字节数；对于包含中文等多字节字符的文本，需要注意编码问题
- `AVG()` 聚合函数：计算所有标题长度的平均值，这是一个标量聚合（返回单个值）
- 全表扫描：此查询需要扫描整个表的所有记录，计算量大，但结果只有一个数值，适合作为全局特征

保存到 HDFS：

```
INSERT OVERWRITE DIRECTORY '/hive_output/headline_avglen'
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
SELECT AVG(length(headline))
FROM news_cleaned;
```

图 4-21 保存到 HDFS 4

查询结果分析：

61.35460192632082

图 4-22 平均标题长度

平均标题长度反映了新闻标题的写作风格和长度规范。较长的标题可能包含更多信息，但也可能影响可读性；较短的标题可能更简洁，但信息量可能不足。这个特征可以用于：

- 文本分类：不同类别的新闻可能有不同的标题长度特征
- 质量评估：异常长或异常短的标题可能表示数据质量问题
- 特征工程：在机器学习模型中，标题长度可以作为特征之一

10. 导出 Hive 结果到本地

```
dolphin@dac5dd1ccb36:/$ cd /home/dolphin/news-bigdata-project
dolphin@dac5dd1ccb36:~/news-bigdata-project$ hdfs dfs -get /hive_output/headline_avglen/
```



图 4-23、4-24 导出 Hive 结果到本地

11. push 至 GitHub

```
Counting objects: 12, done.  
Delta compression using up to 36 threads.  
Compressing objects: 100% (6/6), done.  
Writing objects: 100% (12/12), 156.01 KiB | 0 bytes/s, done.  
Total 12 (delta 0), reused 0 (delta 0)  
remote: To git@github.com:Freya277/news-bigdata-project.git  
7c26c1b..59560ff main -> main  
dolphin@dac5dd1ccb36:~/news-bigdata-project$
```

图 4-25 push 至 Github

五、Spark 实验

5.1 实验概述

本实验作为大数据处理技术项目的高级分析与机器学习阶段，采用 Apache Spark 框架对新闻数据进行深度分析和特征提取。Spark 作为新一代大数据计算引擎，相比 MapReduce 具有内存计算和 DAG 执行引擎的优势，能够实现 10~100 倍的性能提升。本实验的核心价值在于：全面展示 Spark 三大核心组件的应用场景——Spark Core RDD 用于底层数据处理、Spark DataFrame/SQL 用于结构化数据分析、Spark MLlib 用于机器学习特征工程，体现了 Spark 作为统一大数据分析平台的强大能力。




图 5-1 Spark 流程图

5.2 实验目标

本实验设计了三个核心任务，分别展示 Spark 三大组件的应用。

1. 基于 Spark Core RDD 实现新闻作者影响力分数计算：使用 RDD 的底层 API 实现复杂的自定义聚合逻辑（文章数量+标题平均长度加权），展示 RDD 在非结构化数据处理中的灵活性
2. 基于 Spark DataFrame/SQL 完成热门新闻类别分析：使用 DataFrame 的高级 API 和 SQL 接口，实现结构化数据的快速聚合和排序，展示 DataFrame 在数据分析场景下的简洁性和性能优势
3. 基于 Spark MLlib 提取新闻标题 TF-IDF 特征：使用 MLlib 的特征提取工具，实现文本挖掘中的核心特征工程任务，展示 Spark 在机器学习流水线中的应用

5.3 相关概念

5.3.1 Spark Core RDD

RDD (Resilient Distributed Dataset, 弹性分布式数据集) 是 Spark 最核心的底层数据结构, 是分布式的、不可变的元素集合。

核心特性:

- 分布式存储: 数据分散在集群多个节点, 支持并行计算; 每个 RDD 被划分为多个分区 (Partition), 分布在不同节点上。
- 弹性 (Resilient): 基于 lineage (血缘关系) 重建丢失数据, 如果某个分区的数据丢失, Spark 可以根据 RDD 的转换历史重新计算; 还可以根据数据量和集群资源动态调整分区数量, 优化并行度。
- 不可变性 (Immutability): RDD 一旦创建不可修改, 所有转换操作都返回新的 RDD, 保证数据安全和并行计算的正确性。
- 底层接口: 提供 map、reduce、filter、reduceByKey 等底层转换 (Transformation) 和行动 (Action) 操作, 适合低层次的数据处理逻辑。

5.3.2 Spark DataFrame/SQL

DataFrame 是带有 schema (结构信息, 类似数据库表的字段定义) 的分布式数据集, 可理解为 "分布式的表格", 每行是一条记录, 每列有名称和类型。Spark SQL 基于 DataFrame 提供 SQL 接口, 支持用 SQL 语句查询数据, 同时兼容 DataFrame 的 API 操作。

核心特性:

- 结构化: 依赖 schema 描述数据结构 (字段名、类型、是否可空), 适合处理结构化数据 (如 CSV、数据库表、Parquet)。
- 优化执行: 通过 Catalyst 优化器自动优化执行计划, 包括谓词下推、列裁剪、常量折叠等优化技术。性能通常优于 RDD, 因为优化器可以生成更高效的执行计划。支持代码生成 (Code Generation), 将逻辑计划编译为字节码, 进一步提升性能。
- 高层接口: API 更简洁, 类似 Pandas 或 R 的 DataFrame, 减少底层代码编写。
- 统一数据源: 支持多种数据源 (HDFS、Hive、JDBC、Parquet、JSON 等), 通过统一的 API 访问。

5.3.3 Spark MLlib

Spark MLlib 是 Spark 的机器学习库，提供常用的机器学习算法（如分类、回归、聚类）和工具（如特征提取、模型评估），支持构建端到端的机器学习工作流。

核心特性：

- 基于 DataFrame 构建：统一使用 DataFrame 作为数据载体，兼容结构化数据处理。特征列通常存储为 Vector 类型（稀疏向量或稠密向量）。支持从 DataFrame 直接构建特征矩阵。
- 管道化（Pipeline）：支持将特征转换、模型训练等步骤串联为管道（Pipeline）。每个步骤是一个 Transformer（转换器）或 Estimator（估计器）。Pipeline 可以整体保存和加载，便于模型部署。
- 支持复杂数据类型：向量（Vector）：稀疏向量（SparseVector）和稠密向量（DenseVector）。矩阵（Matrix）：用于大规模矩阵运算。支持 LabeledPoint（带标签的数据点）用于监督学习。
- 特征工程工具：Tokenizer：文本分词。HashingTF：词频（Term Frequency。计算 IDF：逆文档频率（Inverse Document Frequency。计算 TF-IDF：词频-逆文档频率，文本挖掘的核心特征。

5.4 实验步骤

1. GitHub 仓库结构准备

```
news-bigdata-project/
spark/
  src/
    com/
      news/
        AuthorInfluenceAnalyzer.java # Core RDD 作者影响力计算
        HotCategoryAnalyzer.java     # DataFrame/SQL 热门类别分析
        HeadlineTFIDF.java           # MLlib TF-IDF 提取
        SparkMain.java               # 主驱动类
    build.sh                         # Java 编译脚本
    spark_result/                   # 本地结果存储目录
```



```
dolphin@08497ec24418:~$ git clone git@github.com:Freya277/news-bigdata-project.git
Cloning into 'news-bigdata-project'...
The authenticity of host 'github.com (20.205.243.166)' can't be established.
ECDSA key fingerprint is SHA256:p2QAMXNIC1TJYweIOttrVc98/R1BUFWu3/LiyKgUfQM.
Are you sure you want to continue connecting (yes/no)? yes
Warning: Permanently added 'github.com,20.205.243.166' (ECDSA) to the list of known hosts.
remote: Enumerating objects: 105, done.
remote: Counting objects: 100% (21/21), done.
remote: Compressing objects: 100% (14/14), done.
remote: Total 105 (delta 1), reused 21 (delta 1), pack-reused 84 (from 2)
Receiving objects: 100% (105/105), 176.36 MiB | 4.02 MiB/s, done.
Resolving deltas: 100% (13/13), done.
Checking connectivity... done.
dolphin@08497ec24418:~$
```

图 5-2、5-3 Github 仓库结构准备

2. 启动 Hadoop

```
dolphin@08497ec24418:/apps/hadoop/sbin$ ./start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as dolphin in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
Starting datanodes
Starting secondary namenodes [08497ec24418]
08497ec24418: Warning: Permanently added '08497ec24418,10.42.42.170' (ECDSA) to the list of known hosts.
Starting resourcemanager
Starting nodemanagers
dolphin@08497ec24418:/apps/hadoop/sbin$ jps
1729 ResourceManager
1989 NodeManager
917 NameNode
1287 SecondaryNameNode
1065 DataNode
2361 Jps
dolphin@08497ec24418:/apps/hadoop/sbin$
```

图 5-4 启动 Hadoop

3. 在 HDFS 创建/news_cleaned 目录并上传文件

```
dolphin@08497ec24418:~$ hdfs dfs -mkdir -p /news_cleaned
dolphin@08497ec24418:~$ hdfs dfs -put /home/dolphin/news-bigdata-project/mapreduce_clean/cleaned_result/news_cleaned/part-r-00000 /news_cleaned/
dolphin@08497ec24418:~$ hdfs dfs -ls /news_cleaned/
Found 1 items
-rw-r--r-- 1 dolphin supergroup 47885079 2025-11-26 08:56 /news_cleaned/part-r-00000
dolphin@08497ec24418:~$
```

图 5-5 上传文件

4. 启动 Spark Local 模式

```

dolphin@08497ec24418:/apps/hadoop/sbin$ cd /apps/spark/bin
dolphin@08497ec24418:/apps/spark/bin$ ./spark-class org.apache.spark.deploy.SparkSubmit --master local[*] --version
Welcome to

  ____      __
 / _  \    /  \
/_  ___/  _/___\
 \___  \/_____\
    \/

version 2.1.3

Using Scala version 2.11.8, Java HotSpot(TM) 64-Bit Server VM, 1.8.0_161
Branch
Compiled by user on 2018-06-26T16:50:16Z
Revision
Url
Type --help for more information.
dolphin@08497ec24418:/apps/spark/bin$

```

图 5-6 SparkLocal 模式

5. 核心代码编写

(1) AuthorInfluenceAnalyzer.java (Spark Core RDD)

```

public class AuthorInfluenceAnalyzer {
    public static JavaPairRDD<String, Double> calculateInfluence(JavaSparkContext sc) {
        // Load data and filter invalid lines
        JavaRDD<String> newsRDD = sc.textFile("hdfs://localhost:8020/news_cleaned/part-r-00000");
        JavaRDD<String> validNewsRDD = newsRDD.filter(new Function<String, Boolean>() {
            @Override
            public Boolean call(String line) throws Exception {
                String[] fields = line.split("\t");
                return fields.length == 5 && !fields[2].isEmpty() && !fields[3].isEmpty();
            }
        });

        // Map to (author, (1, headlineLen)) -> JavaPairRDD (key: author, value: Tuple2)
        JavaPairRDD<String, Tuple2<Integer, Integer>> authorStatsRDD = validNewsRDD.mapToPair(
            new PairFunction<String, String, Tuple2<Integer, Integer>>() {
                @Override
                public Tuple2<String, Tuple2<Integer, Integer>> call(String line) throws Exception {
                    String[] fields = line.split("\t");
                    String author = fields[2];
                    int headlineLen = fields[3].length();
                    return new Tuple2<>(author, new Tuple2<>(1, headlineLen));
                }
            }
        );
    }
}

```

图 5-7 AuthorInfluenceAnalyzer.java

这是基于 SparkCoreRDD 实现的作者影响力分析类,展示了 RDD 在复杂自定义聚合逻辑中的应用。

核心设计要点:

- 数据加载与过滤: `sc.textFile()` 从 HDFS 加载文本文件,返回 `JavaRDD<String>`, 每行是一个字符串。`filter()` 转换操作,过滤无效行: 确保字段数量为 5, 且作者字段 (`fields[2]`) 和标题字段 (`fields[3]`) 非空。惰性执行: `filter` 是转换操作,不会立即执行,只有遇到行动操作 (如 `saveAsTextFile`) 时才会真正计算。

- Map 阶段：数据转换：mapToPair() 将每行文本转换为键值对 (作者, (1, 标题长度))。使用 Tuple2 存储复合值 (文章数 1 和标题长度)。设计思路：将单篇文章的信息封装为 (1, headlineLen)，便于后续聚合时同时统计文章数和标题总长度。
- Reduce 阶段：按 Key 聚合。reduceByKey() 是 RDD 的核心聚合操作，自动将相同 key (作者) 的所有 value 聚合。聚合函数将两个 Tuple2<Integer, Integer> 合并：(count1, len1) 和 (count2, len2) 合并为 (count1+count2, len1+len2)。Shuffle 机制：reduceByKey 会触发 Shuffle，将相同作者的数据发送到同一个分区进行聚合。
- 影响力分数计算：mapValues() 只对 value 进行转换，不改变 key，适合在聚合后计算。计算公式：影响力分数=(总文章数*平均标题长度)/100。业务逻辑：文章数反映作者产量，平均标题长度反映内容质量，两者结合评估综合影响力。
- 排序：sortByKey(false) 按 key 降序排序。

执行流程：1. 加载数据→2. 过滤无效行→3. 转换为键值对→4. 按作者聚合→5. 计算影响力分数→6. 排序→7. 返回结果 RDD

输出结果：输出为 JavaPairRDD<String, Double>，包含 (作者名, 影响力分数) 的键值对，保存为文本文件后可用于后续分析和可视化。

(2) HotCategoryAnalyzer.java (Spark DataFrame/SQL)

```
public class HotCategoryAnalyzer {
    public static Dataset<Row> analyzeHotCategories(SparkSession spark) {
        // Manually build schema (Spark 2.1.3 does not support string schema)
        StructType newsSchema = DataTypes.createStructType(new StructField[]{
            DataTypes.createStructField("category", DataTypes.StringType, true),
            DataTypes.createStructField("date", DataTypes.StringType, true),
            DataTypes.createStructField("authors", DataTypes.StringType, true),
            DataTypes.createStructField("headline", DataTypes.StringType, true),
            DataTypes.createStructField("short_description", DataTypes.StringType, true)
        });

        // Read data with custom schema
        Dataset<Row> newsDF = spark.read()
            .option("delimiter", "\t")
            .schema(newsSchema)
            .csv("hdfs://localhost:8020/news_cleaned/part-r-00000");

        // Add headline length column
        Dataset<Row> newsWithLenDF = newsDF.withColumn("headline_len", functions.length(functions.col("headline")));

        // Calculate hot score: article_count * avg_headline_len / 100
        Dataset<Row> hotCategoryDF = newsWithLenDF.groupBy("category")
            .agg(
                functions.count("category").alias("article_count"),
                functions.avg("headline_len").alias("avg_headline_len")
            )
            .withColumn("hot_score", functions.col("article_count").multiply(functions.col("avg_headline_len")).divide(100))
            .orderBy(functions.col("hot_score").desc());

        return hotCategoryDF;
    }
}
```

图 5-8 HotCategoryAnalyzer.java

这是基于 SparkDataFrame/SQL 实现的热门类别分析类，展示了 DataFrame 在结构化数据分析中的简洁性和性能优势。

核心设计要点：

- Schema 定义：使用 StructType 和 StructField 手动定义 schema，指定每个字段的名称、类型和是否可空。Schema 的作用：告诉 Spark 数据的结构，便于优化执行计划和类型检查
- 数据加载：spark.read().csv() 读取 CSV/TSV 格式文件，返回 Dataset<Row>（即 DataFrame）。option("delimiter", "\t") 指定字段分隔符为制表符，适配 TSV 格式。schema(newsSchema) 应用自定义 schema，确保数据类型正确。优势：相比 RDD，DataFrame 自动处理类型转换和空值处理
- 添加计算列：
withColumn("headline_len", functions.length(functions.col("headline"))) 添加新列。functions.length() 计算字符串长度。functions.col("headline") 引用列，返回 Column 对象。惰性执行：withColumn 是转换操作，不会立即计算，只有遇到行动操作时才执行。
- 分组聚合：groupBy("category") 按类别分组。functions.count("category") 统计每个类别的文章数，functions.avg("headline_len") 计算平均标题长度，.alias() 为聚合结果指定别名，便于后续引用。Catalyst 优化：Spark 的 Catalyst 优化器会自动优化此聚合操作，包括谓词下推、列裁剪等
- 计算热门分数：withColumn("hot_score", ...) 添加热门分数列。使用 multiply() 和 divide() 进行数值计算。公式：热门分数=(文章数量*平均标题长度)/100。业务逻辑：综合文章数量和标题长度，评估类别的热度。
- 排序：orderBy(functions.col("hot_score").desc()) 按热门分数降序排序，.desc() 表示降序，.asc() 表示升序。

技术优势：

- 代码简洁：相比 RDD 版本，DataFrameAPI 更接近 SQL，代码更易读易写
- 性能优化：Catalyst 优化器自动优化执行计划，性能通常优于 RDD
- 类型安全：Schema 提供类型信息，减少运行时错误
- 易于扩展：可以轻松添加更多聚合函数或计算列

执行流程：1. 定义 Schema→2. 加载数据→3. 添加标题长度列→4. 按类别分组聚合→5. 计算热门分数→6. 排序→7. 返回结果 DataFrame

输出结果：输出为 Dataset<Row>，包含 category、article_count、avg_headline_len、hot_score 四列，保存为 CSV 格式后可用于后续分析和可视化。

(3) HeadlineTFIDF.java (Spark MLlib)

```
public class HeadlineTFIDF {
    public static Dataset<Row> extractTFIDF(SparkSession spark) {
        // Manually build schema
        StructType newsSchema = DataTypes.createStructType(new StructField[]{
            DataTypes.createStructField("category", DataTypes.StringType, true),
            DataTypes.createStructField("date", DataTypes.StringType, true),
            DataTypes.createStructField("authors", DataTypes.StringType, true),
            DataTypes.createStructField("headline", DataTypes.StringType, true),
            DataTypes.createStructField("short_description", DataTypes.StringType, true)
        });
    }
}
```

图 5-9 HeadlineTFIDF. java

这是基于 SparkMLlib 实现的 TF-IDF 特征提取类，展示了 MLlib 在文本特征工程中的应用，这是文本挖掘和机器学习的基础步骤。

TF-IDF 算法原理：

- TF (TermFrequency, 词频)：某个词在文档中出现的频率，反映词在文档中的重要性
- IDF (InverseDocumentFrequency, 逆文档频率)：某个词在整个文档集中的稀有程度，IDF 越大表示词越稀有、越有区分度
- $TF-IDF = TF \times IDF$ ：综合词频和逆文档频率，既能反映词在文档中的重要性，又能过滤掉常见词（如“the”、“a”），突出关键词

核心设计要点：

- 数据加载与过滤：加载数据并定义 schema（与 HotCategoryAnalyzer 相同）。filter() 过滤空标题：isNotNull() 和 notEqual("") 确保标题字段有效。数据质量保证：空标题无法进行分词和特征提取，必须提前过滤
- Tokenizer（分词器）：Tokenizer 是 MLlib 的文本处理工具，将文本字符串转换为单词数组。分词规则：默认按空格和标点符号分词，适合英文文本
- HashingTF（词频计算）：HashingTF 使用哈希函数将单词映射到固定维度的特征向量。哈希技巧（HashingTrick）：不需要维护词汇表，通过哈希函数直接将单词映射到特征索引，节省内存。输出：raw_features 列包含稀疏向量（SparseVector），表示每个单词在标题中的词频
- IDF（逆文档频率）：IDF 是 Estimator（估计器），需要先 fit() 训练模型，再 transform() 应用。训练 IDF 模型：扫描所有文档，统计每个词（通过哈希索引）出现在多少个文档中；计算每个词的 IDF 值： $IDF = \log(\text{文档总数} / \text{包含该词的文档数})$ 。应用模型：将 TF 特征向量与 IDF 值相乘，得到 TF-IDF 特征向量。输出：tfidf_features 列包含 TF-IDF 特征向量（稀疏向量）
- 结果选择：select("headline", "tfidf_features") 只保留原始标题和 TF-IDF 特征。其他列（category、date 等）被丢弃，因为特征提取只需要标题

执行流程：1. 加载数据→2. 过滤空标题→3. 分词（Tokenizer）→4. 计算词频（HashingTF）→5. 训练 IDF 模型→6. 应用 IDF 计算 TF-IDF→7. 选择结果列

输出结果: 输出为 Dataset<Row>, 包含 headline(原始标题)和 tfidf_features(2000 维 TF-IDF 特征向量) 两列。TF-IDF 特征可以用于:

- 文本分类: 将特征向量输入分类模型 (如逻辑回归、SVM)
- 文本聚类: 使用特征向量进行 K-means 聚类
- 相似度计算: 通过向量相似度 (如余弦相似度) 计算标题之间的相似性
- 关键词提取: TF-IDF 值高的词通常是关键词

保存格式: TF-IDF 特征保存为 Parquet 格式, Parquet 是列式存储格式, 支持复杂数据类型 (如向量), 压缩率高, 适合大规模机器学习数据。

(4) SparkMain.java (主驱动类)

```
public class SparkMain {
    public static void main(String[] args) {
        // Spark configuration (compatible with Spark 2.1.3)
        SparkConf conf = new SparkConf()
            .setAppName("NewsBigDataAnalysis")
            .setMaster("local[*]");
        JavaSparkContext sc = new JavaSparkContext(conf);
        SparkSession spark = SparkSession.builder().config(conf).getOrCreate();

        try {
            // 1. Author Influence Analysis (return JavaPairRDD)
            JavaPairRDD<String, Double> authorInfluenceRDD = AuthorInfluenceAnalyzer.calculateInfluence(sc);

            // Fix: Use Function to convert Tuple2 to String (compatible with Spark 2.1.3)
            JavaPairRDD<String, String> influenceStrRDD = authorInfluenceRDD.mapValues(
                new Function<Double, String>() {
                    @Override
                    public String call(Double value) throws Exception {
                        return value.toString();
                    }
                }
            );
            // Save as text file (key\tvalue)
            influenceStrRDD.saveAsTextFile("hdfs://localhost:8020/spark_output/author_influence");

            // 2. Hot Category Analysis
            Dataset<Row> hotCategoryDF = HotCategoryAnalyzer.analyzeHotCategories(spark);
        } catch (Exception e) {
            e.printStackTrace();
        }
    }
}
```

图 5-10 SparkMain 类

Spark 任务主驱动类, 统筹整个新闻数据分析流程

6. 编译&运行脚本

```
cd ~/news-bigdata-project/spark
chmod +x build.sh
./build.sh

# 运行Spark任务
spark-submit --class com.news.SparkMain --master local[*] build/lib/news-spark.jar
```

图 5-11 编译运行脚本

7. 查看结果并下载到本地


```
dolphin@08497ec24418:~/news-bigdata-project/spark$ hdfs dfs -ls /spark_output/
Found 3 items
drwxr-xr-x  - dolphin supergroup      0 2025-11-26 09:11 /spark_output/auth
or_influence
drwxr-xr-x  - dolphin supergroup      0 2025-11-26 09:12 /spark_output/head
line_tfidf
drwxr-xr-x  - dolphin supergroup      0 2025-11-26 09:12 /spark_output/hot_
categories
dolphin@08497ec24418:~/news-bigdata-project/spark$

dolphin@08497ec24418:~/news-bigdata-project/spark$ hdfs dfs -get /spark_output/*
~/news-bigdata-project/spark/spark_result/
dolphin@08497ec24418:~/news-bigdata-project/spark$ ls ~/news-bigdata-project/spa
rk/spark_result/
author_influence  headline_tfidf  hot_categories
dolphin@08497ec24418:~/news-bigdata-project/spark$
```

图 5-12、5-13 查看结果并下载到本地

8. 推送到 Github

```
Counting objects: 38, done.
Delta compression using up to 36 threads.
Compressing objects: 100% (35/35), done.
Writing objects: 100% (38/38), 12.11 MiB | 897.00 KiB/s, done.
Total 38 (delta 4), reused 0 (delta 0)
remote: Resolving deltas: 100% (4/4), completed with 1 local object.
To git@github.com:Freya277/news-bigdata-project.git
 5d66cfb..f516be8  main -> main
dolphin@08497ec24418:~/news-bigdata-project$
```

图 5-14 推送到 Github

六、HBase 实验

6.1 实验概述

本实验作为大数据处理技术项目的终态存储与在线查询阶段，采用 Apache HBase 作为 NoSQL 数据库，存储 MapReduce、Hive、Spark 等前置实验的核心分析结果。HBase 是基于 HDFS 的分布式列式数据库，具有高吞吐量写入和毫秒级随机查询的能力，特别适合存储大规模结构化数据并支持快速 Key-Value 查询。本实验的核心价值在于：实现大数据流水线的闭环——从 MapReduce 的数据清洗、Hive 的数据仓库分析、Spark 的高级计算，到 HBase 的持久化存储和在线查询，体现了大数据生态系统中不同组件各司其职、协同工作的完整架构。




图 6-1 HBase 流程图

6.2 实验目标

1. 设计适配的 HBase 表结构：存储 Spark 核心分析结果（作者影响力分数、热门新闻类别排名、标题 TF-IDF 向量）和 Hive 关键统计结果（年度新闻数量、标题平均长度），设计合理的 RowKey 和列族结构，支持高效查询
2. 通过 Java API 实现批量写入：从 HDFS 读取前置实验结果，通过 HBase Java API 批量写入对应表中，确保“MapReduce→Hive→Spark→HBase”数据流水线闭环，实现数据的持久化存储
3. 基于 HBase Shell/Java API 完成快速查询验证：通过 RowKey 进行精准查询，体现 HBase 在 Key-Value 查询场景下的毫秒级响应优势，验证数据正确性

4. 将 HBase 操作结果推送至 GitHub：保存查询日志、表结构文档等，完成项目全流程追溯，体现工程化实践

6.3 实验核心设计

6.3.1 HBase 表结构设计

表名	RowKey 设计	列族	列名	数据类型	数据来源
news_author_influence	作者名 (唯一)	profile	influence_score	Double	Spark /spark_output/author_influence
news_category_hot	新闻类别 (唯一)	stats	article_count	Int	Spark /spark_output/hot_categories
			avg_headline_len	Double	Spark 分析结果
			hot_score	Double	Spark 分析结果 (综合排名分数)
news_headline_tfidf	新闻 ID (自定义)	vector	tfidf_features	String	Spark /spark_output/headline_tfidf
news_yearly_stats	年份 (如 2012)	metrics	news_count	Int	Hive /hive_output/yearly_count
	total (固定值)		avg_headline_len	Double	Hive /hive_output/headline_avglen

表 6-1 HBase 表结构设计

6.3.2 数据映射规则

- 新闻 ID 生成：对 Spark TF-IDF 结果中的每条标题，按“headline_序号”生成唯一 ID（如 headline_001）。
- 数值类型转换：Hive/Spark 结果中的 Int/Double 类型直接存储，TF-IDF 向量以逗号分隔的字符串存储（适配 HBase 字符串存储优化）。
- RowKey 设计原则：确保唯一标识，支持快速精准查询（如按作者名、类别名、年份直接定位）。

6.4 实验步骤

1. GitHub 仓库结构准备

```
news-bigdata-project/
hbase/
  src/
    com/
      news/
        HBaseDataWriter.java
        HBaseQuery.java
    build.sh

dolphin@e76a3605cec5:~$ git clone git@github.com:Freya277/news-bigdata-project.git
Cloning into 'news-bigdata-project'...
remote: Enumerating objects: 219, done.
remote: Counting objects: 100% (135/135), done.
remote: Compressing objects: 100% (87/87), done.
remote: Total 219 (delta 38), reused 119 (delta 22), pack-reused 84 (from 2)
Receiving objects: 100% (219/219), 188.49 MiB | 4.28 MiB/s, done.
Resolving deltas: 100% (50/50), done.
Checking connectivity... done.
Checking out files: 100% (67/67), done.
dolphin@e76a3605cec5:~$
```

图 6-2、6-3 Github 仓库结构准备

2. 启动 Hadoop

```
dolphin@e76a3605cec5:~/news-bigdata-project$ cd /apps/hadoop/sbin
dolphins@e76a3605cec5:/apps/hadoop/sbin$ ./start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as dolphin in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [e76a3605cec5]
e76a3605cec5: Warning: Permanently added 'e76a3605cec5,10.42.11.35' (ECDSA) to t
he list of known hosts.
Starting resourcemanager
Starting nodemanagers
dolphins@e76a3605cec5:/apps/hadoop/sbin$ jps
642 DataNode
867 SecondaryNameNode
1444 NodeManager
1300 ResourceManager
1961 Jps
489 NameNode
dolphins@e76a3605cec5:/apps/hadoop/sbin$
```

图 6-4 启动 Hadoop

3. 上传结果到 HDFS

```

dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -mkdir -p /spark_output/author_influence
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -mkdir -p /spark_output/hot_categories
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -mkdir -p /spark_output/headline_tfidf
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -mkdir -p /hive_output/yearly_count
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -mkdir -p /hive_output/headline_avglen

dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -put ~/news-bigdata-project/spark/spark_result/author_influence/* /spark_output/author_influence/
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -put ~/news-bigdata-project/spark/spark_result/hot_categories/* /spark_output/hot_categories/
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -put ~/news-bigdata-project/spark/spark_result/headline_tfidf/* /spark_output/headline_tfidf/
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -put ~/news-bigdata-project/hive_result/hive_output/yearly_count/* /hive_output/yearly_count/
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -put ~/news-bigdata-project/hive_result/hive_output/headline_avglen/* /hive_output/headline_avglen/
dolphin@e76a3605cec5:/apps/hadoop/sbin$

dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -ls /spark_output/author_influence/
Found 3 items
-rw-r--r--  1 dolphin supergroup          0 2025-11-27 13:18 /spark_output/author_influence/_SUCCESS
-rw-r--r--  1 dolphin supergroup    620868 2025-11-27 13:18 /spark_output/author_influence/part-00000
-rw-r--r--  1 dolphin supergroup    716277 2025-11-27 13:18 /spark_output/author_influence/part-00001
dolphin@e76a3605cec5:/apps/hadoop/sbin$ hdfs dfs -ls /spark_output/hot_categories/
Found 4 items
-rw-r--r--  1 dolphin supergroup          0 2025-11-27 13:19 /spark_output/hot_categories/_SUCCESS
-rw-r--r--  1 dolphin supergroup    1838 2025-11-27 13:19 /spark_output/hot_categories/part-00000-605d03c1-585f-4d49-a4fd-445a13656261.csv
-rw-r--r--  1 dolphin supergroup    398803 2025-11-27 13:19 /spark_output/hot_categories/part-00001-605d03c1-585f-4d49-a4fd-445a13656261.csv
-rw-r--r--  1 dolphin supergroup          0 2025-11-27 13:19 /spark_output/hot_categories/part-00002-605d03c1-585f-4d49-a4fd-445a13656261.csv

```

图 6-5、6-6、6-7 上传结果到 HDFS

4. 启动 HBase 服务

```
dolphin@e76a3605cec5:/apps/hadoop/sbin$ /apps/hbase/bin/start-hbase.sh
localhost: starting zookeeper, logging to /apps/hbase/bin/../logs/hbase-dolphin-
zookeeper-e76a3605cec5.out
starting master, logging to /apps/hbase/logs/hbase-dolphin-master-e76a3605cec5.o
ut
starting regionserver, logging to /apps/hbase/logs/hbase-dolphin-1-regionserver-
e76a3605cec5.out
dolphin@e76a3605cec5:/apps/hadoop/sbin$ jps
642 DataNode
867 SecondaryNameNode
4947 Jps
1444 NodeManager
1300 ResourceManager
4565 HRegionServer
489 NameNode
4349 HMaster
4143 HQuorumPeer
dolphin@e76a3605cec5:/apps/hadoop/sbin$ /apps/hbase/bin/hbase shell
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/apps/hbase/lib/slf4j-log4j12-1.7.5.jar!/org/s
lf4j/impl/StaticLoggerBinder.class]
```

图 6-8 启动 HBase 服务

5. 通过 HBaseShell 创建表

```
hbase(main):001:0> create 'news_author_influence', 'profile'
0 row(s) in 2.7010 seconds

=> Hbase::Table - news_author_influence
hbase(main):002:0> create 'news_category_hot', 'stats'
0 row(s) in 2.2650 seconds

=> Hbase::Table - news_category_hot
hbase(main):003:0> create 'news_headline_tfidf', 'vector'
0 row(s) in 2.9130 seconds

=> Hbase::Table - news_headline_tfidf
hbase(main):004:0> create 'news_yearly_stats', 'metrics'
0 row(s) in 1.9570 seconds

=> Hbase::Table - news_yearly_stats

hbase(main):005:0> list
TABLE
news_author_influence
news_category_hot
news_headline_tfidf
news_yearly_stats
newsdb:news
5 row(s) in 0.0440 seconds

=> ["news_author_influence", "news_category_hot", "news_headline_tfidf", "news_y
early_stats", "newsdb:news"]
hbase(main):006:0> █
```

图 6-9、6-10 创造表

6. Java API 编写

(1) 数据写入工具类: HBaseDataWriter.java (适配多文件读取)

```

public class HBaseDataWriter {
    // HDFS paths for result directories
    private static final String HDFS_AUTHOR_DIR = "hdfs://localhost:8020/spark_output/author_influence/";
    private static final String HDFS_CATEGORY_DIR = "hdfs://localhost:8020/spark_output/hot_categories/";
    private static final String HDFS_YEARLY_DIR = "hdfs://localhost:8020/hive_output/yearly_count/";
    private static final String HDFS_AVGLEN_DIR = "hdfs://localhost:8020/hive_output/headline_avglen/";

    public static void main(String[] args) {
        // HBase configuration
        Configuration hbaseConf = HBaseConfiguration.create();
        hbaseConf.set("hbase.zookeeper.quorum", "localhost");
        hbaseConf.set("hbase.zookeeper.property.clientPort", "2181");

        // HDFS configuration
        Configuration hdfsConf = new Configuration();
        hdfsConf.set("fs.defaultFS", "hdfs://localhost:8020");

        try (Connection conn = ConnectionFactory.createConnection(hbaseConf);
             FileSystem fs = FileSystem.get(hdfsConf)) {

            System.out.println("===== Starting to read Spark Author Influence file =====");
            writeAuthorInfluence(conn, fs, HDFS_AUTHOR_DIR);
            System.out.println("===== Starting to read Spark Hot Category file =====");
            writeHotCategory(conn, fs, HDFS_CATEGORY_DIR);
            System.out.println("===== Starting to read Hive Yearly Stats file =====");
            writeYearlyStats(conn, fs, HDFS_YEARLY_DIR);
            System.out.println("===== Starting to read Hive Average Headline Length file =====");
            writeAvgHeadlineLen(conn, fs, HDFS_AVGLEN_DIR);

            System.out.println("All Spark/Hive results written to HBase successfully!");

        } catch (Exception e) {
            e.printStackTrace();
        }
    }
}

```

图 6-11 HBaseDataWriter.java

这是 HBase 数据写入工具类，负责将 HDFS 上存储的 Spark/Hive 分析结果批量写入 HBase 对应表中，实现“计算结果→存储”的数据流转。

核心设计要点：

- 配置管理：HBase 配置：通过 HBaseConfiguration.create() 创建配置对象，设置 ZooKeeper 地址和端。HDFS 配置：创建独立的 Configuration 对象，设置 HDFS 地址。
- 资源管理：使用 try-with-resources 语句自动管理资源。自动关闭资源，避免内存泄露和连接泄露。
- 多文件读取：fs.listStatus(newPath(dirPath)) 列出目录下所有文件。遍历所有文件，跳过_SUCCESS 标记文件（MapReduce/Spark 生成的成功标记）。对每个数据文件使用 BufferedReader 逐行读取，支持大文件处理
- 数据格式解析（不同数据源有不同的解析逻辑）：作者影响力数据（来自 Spark RDD 输出）、热门类别数据（来自 Spark DataFrame 输出）、年度统计数据（来自 Hive 输出）、标题平均长度（来自 Hive 输出）。
- HBase 写入操作：代码中逐条写入，实际生产环境可以使用 table.put(List<Put>) 批量写入，提升性能。

- 异常处理：捕获 `NumberFormatException`：处理数值转换错误，跳过格式异常的数据行。捕获 `Exception`：处理文件读取、网络连接等异常，确保程序健壮性。输出错误日志：便于调试和问题定位。

执行流程：1. 初始化配置→2. 建立连接→3. 遍历 HDFS 文件→4. 解析数据格式→5. 创建 Put 对象→6. 写入 HBase→7. 关闭资源

数据流转意义：

- 将 Spark 和 Hive 的计算结果持久化到 HBase，实现数据的长期存储
- 为后续的在线查询提供数据基础，支持毫秒级的随机访问
- 完成大数据流水线的闭环，从计算到存储的完整链路

(2) 查询验证工具类：HBaseQuery.java

```
public class HBaseQuery {
    // Define the report output path
    private static final String REPORT_PATH = "/home/dolphin/news-bigdata-project/hbase/hbase_result/query_report.txt";
    public static void main(String[] args) {
        Configuration conf = HBaseConfiguration.create();
        conf.set("hbase.zookeeper.quorum", "localhost");
        conf.set("hbase.zookeeper.property.clientPort", "2181");
        try (PrintWriter writer = new PrintWriter(new FileWriter(REPORT_PATH));
            Connection conn = ConnectionFactory.createConnection(conf)) {

            writer.println("==== HBase Query Results (Readable Report) =====");

            // 1. Query author influence (Lee Moran)
            writer.println("1. Author Influence Query (Lee Moran)");
            queryAuthorInfluence(conn, "Lee Moran", writer);

            // 2. Query hot category (POLITICS)
            writer.println("\n2. Hot News Category Query (POLITICS)");
            queryHotCategory(conn, "POLITICS", writer);

            // 3. Query news count for year 2022
            writer.println("\n3. Yearly News Count Query (2022)");
            queryYearlyStats(conn, "2022", writer);

            // 4. Query average headline length
            writer.println("\n4. Average Headline Length Query");
            queryAvgHeadlineLen(conn, writer);

            writer.println("\n==== Query Complete =====");
            System.out.println("Readable report generated: " + REPORT_PATH);

        } catch (Exception e) {
            e.printStackTrace();
        }
    }
}
```

图 6-12 HBaseQuery.java

这是 HBase 数据查询验证工具类，负责通过 HBase Java API 查询已写入的数据，验证数据正确性并生成可读报告。

核心设计要点：

- 查询设计：基于 RowKey 的精准查询：使用 Get 对象指定 RowKey，HBase 通过 RowKey 直接定位到对应的 Region，实现毫秒级查询。HBase 优势：相比关系型数据库的全表扫描，HBase 的 RowKey 查询是 $O(1)$ 时间复杂度，非常适合点查询场景。

- 查询执行：Getget=newGet(Bytes.toBytes(rowKey))：创建 Get 对象，RowKey 需要转换为字节数组。Resultresult=table.get(get)：执行查询，返回 Result 对象。
result.isEmpty()：检查查询结果是否为空，处理数据不存在的情况。
- 数据解析：HBase 存储的是字节数组，需要根据列的类型进行正确的转换。
- 资源管理：使用 try-with-resources 管理 PrintWriter 和 Connection。每个查询方法中正确关闭 Table 对象，释放资源。

执行流程：1. 初始化配置和文件输出流→2. 建立 HBase 连接→3. 执行多个查询→4. 解析结果并输出→5. 关闭资源

7. 编译脚本

```
mkdir -p build/classes
mkdir -p build/lib

HBASE_HOME=/apps/hbase
HADOOP_HOME=/apps/hadoop
JAVA_HOME=/apps/java

$JAVA_HOME/bin/javac -cp $(echo $HBASE_HOME/lib/*.jar | tr ' ' ':')$(echo $HADOOP_HOME/share/hadoop/common/*.jar | tr ' ' ':')
' ':'') -d build/classes src/com/news/*.java

$JAVA_HOME/bin/jar -cvfm hbase-news.jar MANIFEST.MF -C build/classes .

cp hbase-news.jar build/lib/
echo "Success! Jar file: build/lib/hbase-news.jar"
```

图 6-13 编译脚本

8. 编译代码

```
dolphin@5114782c1c53:~$ cd ~/news-bigdata-project/hbase
dolphin@5114782c1c53:~/news-bigdata-project/hbase$ chmod +x build.sh
dolphin@5114782c1c53:~/news-bigdata-project/hbase$ ./build.sh
已添加清单
正在添加: com/(输入 = 0) (输出 = 0)(存储了 0%)
正在添加: com/news/(输入 = 0) (输出 = 0)(存储了 0%)
正在添加: com/news/HBaseQuery.class(输入 = 5462) (输出 = 2647)(压缩了 51%)
正在添加: com/news/HBaseDataWriter.class(输入 = 8517) (输出 = 3955)(压缩了 53%)
Success! Jar file: build/lib/hbase-news.jar
dolphin@5114782c1c53:~/news-bigdata-project/hbase$
```

图 6-14 编译代码

9. 查询验证 (HBaseShell+JavaAPI)

(1) HBaseShell 查询 (体现 Key-Value 快速查询)

```

hbase(main):011:0> get 'news_author_influence', 'Lee Moran'
COLUMN          CELL
profile:influence_score timestamp=1764251651288, value=@\x9F\xEAz\xE1G\xAE\x14
ore
1 row(s) in 0.2550 seconds

hbase(main):012:0> get 'news_category_hot', 'POLITICS'
COLUMN          CELL
stats:article_count timestamp=1764251669028, value=\x00\x00\x8B\x11
stats:avg_headline_l timestamp=1764251669028, value=@P\x10\x1EBH\xED\xDF
en
stats:hot_score    timestamp=1764251669028, value=@\xD6V\x933333
3 row(s) in 0.2890 seconds

hbase(main):013:0> get 'news_yearly_stats', '2022'
COLUMN          CELL
metrics:news_count timestamp=1764251672071, value=\x00\x00\x05v
1 row(s) in 0.0120 seconds

hbase(main):014:0> get 'news_yearly_stats', 'total'
COLUMN          CELL
metrics:avg_headline timestamp=1764251679488, value=@N\xADc\x98\x8ER\xC1
_len
1 row(s) in 0.0050 seconds

hbase(main):015:0> scan 'news_author_influence', {LIMIT => 5}
ROW              COLUMN+CELL
#DoctorsSpeakOut, Co column=profile:influence_score, timestamp=1764251668559, v
ntributor#DoctorsSpe alue=?\xE3333333
akOut is a coalition
of physicians seeki
ng high qua...
'The Koch Sisters', column=profile:influence_score, timestamp=1764251668558, v
ContributorSo not re alue=?\xD5\x1E\xB8Q\xEB\x85\x1F
lated to those guys
10,000 Small Busines column=profile:influence_score, timestamp=1764251668557, v
ses Program, Contrib alue=?\xDA\xE1G\xAE\x14z\xE1
utorAn investment to
help entrepreneurs
create jobs and econ
omic o...
lin20, ContributorVi column=profile:influence_score, timestamp=1764251668556, v

```


图 6-15、6-16 HBase Shell 查询

(2) JavaAPI 查询验证

```

dolphin@5114782c1c53:~/news-bigdata-project/hbase$ java -cp $(echo /apps/hbase/lib/*.jar | tr ' ' ':'):build/lib/hbase-news.jar com.news.HBaseQuery
log4j:WARN No appenders could be found for logger (org.apache.hadoop.security.Groups).
log4j:WARN Please initialize the log4j system properly.
log4j:WARN See http://logging.apache.org/log4j/1.2/faq.html#noconfig for more info.
Author: Lee Moran | Influence Score: 2042.62
Category: POLITICS | Article Count: 35601 | Hot Score: 22874.3
Year: 2022 | News Count: 1398
Overall Average Headline Length: 61.35460192632082 characters
Readable report generated: /home/dolphin/news-bigdata-project/hbase/hbase_result/query_report.txt

```

```

===== HBase Query Results (Readable Report) =====

1. Author Influence Query (Lee Moran)
Author: Lee Moran | Influence Score: 2042.62

2. Hot News Category Query (POLITICS)
Category: POLITICS
  - Article Count: 35601
  - Avg Headline Length: 64.25184685823432
  - Hot Score: 22874.3

3. Yearly News Count Query (2022)
Year: 2022 | News Count: 1398


4. Average Headline Length Query
Overall Average Headline Length: 61.35460192632082 characters

===== Query Complete =====

```

图 6-17、6-18 Java API 查询验证

10. 保存查询日志到本地




```

dolphin@5114782c1c53:~/news-bigdata-project/hbase$ /apps/hbase/bin/hbase shell -
n << EOF > ~/news-bigdata-project/hbase/hbase_result/query_log.txt
> get 'news_author_influence', 'Lee Moran'
> get 'news_category_hot', 'POLITICS'
> get 'news_yearly_stats', '2022'
> get 'news_yearly_stats', 'total'
> scan 'news_author_influence', {LIMIT => 5}
> EOF
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/apps/hbase/lib/slf4j-log4j12-1.7.5.jar!/org/s
lf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/apps/hadoop/share/hadoop/common/lib/slf4j-log
4j12-1.7.25.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory]
dolphin@5114782c1c53:~/news-bigdata-project/hbase$

```

图 6-19 保存查询日志到本地

11. 推送至 Github



```

Counting objects: 18, done.
Delta compression using up to 36 threads.
Compressing objects: 100% (13/13), done.
Writing objects: 100% (18/18), 15.29 KiB | 0 bytes/s, done.
Total 18 (delta 3), reused 0 (delta 0)
remote: Resolving deltas: 100% (3/3), completed with 3 local objects.
To git@github.com:Freya277/news-bigdata-project.git
   f4d8e09..c674b17  main -> main
dolphin@5114782c1c53:~/news-bigdata-project$

```

图 6-20 推送到 Github

七、总结

本研究基于 Hadoop 大数据生态系统核心组件，构建了一套覆盖数据预处理、分析挖掘、特征提取至结果存储查询的完整新闻数据处理与分析流水线。通过 MapReduce 完成原始数据的清洗与标准化处理，借助 Hive 搭建结构化数据仓库并实现多维度统计分析，利用 Spark 的内存计算与 DAG 引擎优势完成深度挖掘与文本特征提取，最终通过 HBase 实现分析结果的持久化存储与毫秒级随机查询，形成“预处理 - 分析 - 计算 - 存储”的全流程闭环，实现了数据在不同组件间的无缝流转与高效协同。

实验过程中，各组件各司其职、精准适配场景需求：MapReduce 发挥分布式批处理优势攻克海量非结构化数据清洗难题，Hive 以类 SQL 接口降低结构化数据分析门槛，Spark 凭借内存计算与 MLlib 组件实现高效深度挖掘与特征工程，HBase 依托列式存储特性满足大规模数据的快速存储与查询需求。整套方案充分验证了大数据生态组件在不同数据处理环节的核心技术优势，展现了生态协同的高效性与实用性。研究结果不仅为新闻数据的深度挖掘与价值提炼提供了高效可行的技术方案，也为同类文本数据的全流程处理分析提供了可复用的工程实践参考。

未来研究可从三方面进一步拓展：一是深化智能分析能力，引入逻辑回归、LSTM 等更多机器学习与深度学习模型，基于已提取的 TF-IDF 文本特征，开展新闻分类、主题聚类、情感倾向分析等更复杂的智能任务；二是优化性能瓶颈，针对分布式计算与存储的资源消耗问题，探索多组件协同调度与动态资源分配策略，提升大规模数据处理的吞吐量与响应速度；三是拓展实时应用场景，结合 Flink 等实时计算框架，构建新闻数据的实时分析与智能推送系统，打破批处理局限，满足时效性场景需求。